

YYB 量化研究平台： Alpha 因子挖掘、分类与多策略组合的系统框架

YYB 研究团队

2026 年 5 月 29 日

摘要

本文介绍 YYB 量化研究平台，一个面向 A 股市场的集成化 Alpha 因子挖掘、经济分类和多策略组合构建系统。平台涵盖 89 个日频数据字段、5515 只股票、970 个交易日（2020–2023 年），支持因子表达式解析、单因子回测及四种组合策略（等权、ICIR 加权、Ridge 正则化、LightGBM）。核心创新包括：761 个单因子的自动经济分类（动量、反转、微观结构、流动性、波动率五大类，以及 512 个跨类别的“混合”因子）；子进程隔离计算确保内存安全；表达式编码权重实现因子零成本复用。通过 55+ 组合的系统实验，我们发现：(1) 被标注为“混合/剔除”的因子平均组合 Sharpe 达 9.11，远超明确风格因子（7.43）；(2) LightGBM 在混合 + 明确因子组合中达到 Sharpe=12.51；(3) ICIR 加权在小规模组合（ $N \leq 5$ ）中持续优于等权；(4) 跨风格选择带来的分散化收益远高于同风格内优化。论文最终提交 10 个两两相关性低于 0.5 的竞争因子。

1 引言

A 股市场的 Alpha 因子挖掘面临独特挑战：高股票数量（5515 只）、有限交易历史（970 天）、复杂的市场微观结构。传统方法要么依赖手工因子构建（覆盖范围有限），要么通过系统枚举产生高度相关的冗余信号。YYB 平台通过以下设计回应这些挑战：(1) 支持 89 个数据字段和 20+ 操作符的灵活表达式解析器；(2) 自动经济含义分类；(3) 四种互补的组合策略，严格 OOS 评估；(4) 交互式 Web 研究界面。

平台的三个设计原则：**经济可解释性**——每个因子必须可追溯到特定的市场机制；**内存安全**——所有重计算在独立子进程中运行，保证内存释放；**可复现性**——所有回测使用相同的数据窗口和评估指标。

我们的实验揭示了一个反直觉的发现：被分类器标注为“混合”（无法归入单一经济分组）的因子，构成了**组合投资的最强输入集**。这些混合因子占总因子数的 67%，其平均组合 Sharpe 为 9.11——比最佳单风格因子高 22.6%，比风格均衡组合高 47%。我们认为这是因为混合因子天然具备多维度性：它们跨越多个经济机制，每个因子内部已蕴含分散化效应。

2 平台架构

2.1 数据管线

平台接入 5515 只 A 股、970 个交易日（2020-01-02 至 2023-12-29）的日频数据，包含：

- 89 个基础数据字段：OHLCV、收益率、成交量、波动率、衍生指标
- 每日有效股票宇宙掩码
- 未来 5 日收益标签（与比赛规格一致）
- 线程安全的双重检查锁定惰性加载

2.2 表达式解析器

解析器支持丰富的操作符集合：

- 截面操作符：rank, zscore, signed_power
- 时序操作符：ts_rank, ts_mean, ts_delta, ts_corr
- 算术运算：+、-、*、/、一元取反
- 条件型：基于成交量/波动率的布尔表达式

每个表达式被解析为惰性执行的操作流水线，输出 $(n_dates \times n_stocks)$ 的 float32 矩阵。

2.3 回测引擎

所有回测严格遵循比赛规格：每个交易日选取因子值排名前 10% 的股票做多，计算相对全市场等权的超额收益。

2.3.1 指标体系

以下指标均基于日超额收益序列 $\{r_t\}$ 计算：

$$\text{年化超额} = \bar{r} \times 250 \quad (1)$$

$$\text{Sharpe} = \frac{\bar{r} \times 250}{\sigma_r \times \sqrt{250}} \quad (2)$$

$$\text{Pearson IC} = \frac{1}{T} \sum_{t=1}^T \text{corr}(f_t, \text{Label}_t) \quad (3)$$

$$\text{ICIR} = \frac{\text{mean}(\text{RankIC}_t)}{\text{std}(\text{RankIC}_t)} \quad (4)$$

$$\text{换手率} = \frac{1}{T-1} \sum_{t=2}^T \left(1 - \frac{|\text{top}_{t-1} \cap \text{top}_t|}{\max(|\text{top}_{t-1}|, |\text{top}_t|)} \right) \quad (5)$$

$$\text{Fitness} = \text{Sharpe} \times \sqrt{\frac{|\text{年化超额}|}{\max(\text{换手率}, 0.125)}} \quad (6)$$

$$\text{最大回撤} = \max_t (\text{peak}_t - \text{cum}_t) \quad (7)$$

$$\text{Margin(bps)} = \frac{\bar{r}}{\text{mean}(|r_t|)} \times 10000 \quad (8)$$

比赛评分指标为 50% Pearson IC + 50% Top-10% 年化超额收益。

2.4 因子分类系统

每个因子通过表达式模式分析自动归入 8 个经济分组之一：

表 1: 因子分类分组统计

分组	数量	平均 IC
流动性	89	0.0183
微观结构	54	0.0145
反转	28	0.0143
动量	25	0.0139
波动率	18	0.0135
基本面	1	0.0148
规模	2	0.0129
混合/剔除	512	0.0120

无法明确归入单一分组的因子（信号跨多类别或包含矛盾模式）被标注为”混合/剔除”。正如第5节所示，这些混合因子——与直觉相反——构成了组合投资的最强因子池。

3 组合方法论

3.1 问题表述

给定 N 个基础 Alpha 因子，每日截面标准化后求加权组合： $F_c = \sum_i w_i \cdot \text{zscore}(F_i)$ 。所有组合均基于 2023 年 OOS 期评估，ICIR 和 Ridge 方法额外使用全期 2020–2023 估计权重。

3.2 等权 (EW)

基准方法： $w_i = 1/N$ 。简单、稳健，作为其他方法的比较基准。

3.3 ICIR 加权

权重与 IC 信息比率成正比：

$$w_i \propto \max(0.1, \text{ICIR}_i) \quad (9)$$

其中 $\text{ICIR}_i = \text{mean}(\text{RankIC}_t) / \text{std}(\text{RankIC}_t)$ 由每日 Rank IC 序列计算。预测信号更稳定的因子获得更高权重。0.1 的下限防止负权重或零权重。

3.4 Ridge 正则化最小方差

借鉴 Ridge 回归的投资组合优化思想：

$$w_i \propto \frac{1}{\sigma_i + \lambda_{\text{median}}} \quad (10)$$

其中 σ_i 是因子 i 的日收益波动率， $\lambda = \text{median}(\{\sigma_j\})$ 提供 L2 正则化。该方法惩罚高波动因子，并天然处理多重共线性。

3.5 LightGBM (LGB)

非线性方法：在 2020–2022 年数据上训练梯度提升树集成模型，在 2023 年 OOS 上预测：

$$F_c = \text{LGBM}_{\text{train}(2020-2022)}(F_1, \dots, F_N) \text{ 在 2023 年评估} \quad (11)$$

关键超参数： $n_{\text{estimators}} = 50$, $\text{max_depth} = 2$, $\text{subsample} = 0.7$, $\ell_1 = 5.0$, $\ell_2 = 5.0$ 。训练和 OOS 之间设 5 天 Purge 防止标签泄露。训练好的预测矩阵以压缩.npy 文件缓存（约 5MB），便于嵌套组合中高效复用。

3.6 EW 结果的符号化展开复用

等权、ICIR 和 Ridge 组合产生编码了方法和权重的符号表达式（如 `superalpha[icir](0.35*A + 0.65*B)`）。作为输入复用时，系统解析表达式恢复基础因子及其原始权重，实现零成本的嵌套组合。

4 实验设计

4.1 实验矩阵

我们设计了一个 $4 \times 4 \times 3$ 实验矩阵：

- 4 种组合方法：EW、ICIR、Ridge、LGB
- 4 种因子池：
 1. 明确风格（Clean）：247 个清晰分组因子
 2. 仅混合（Mixed）：512 个混合/剔除因子
 3. 风格均衡（Style-balanced）：5 个明确组各取 2 个
 4. 全部组合（All）：明确 + 混合，按 Sharpe 取 Top-N
- 多级别规模： $N \in \{3, 5, 8, 10, 15, 20\}$

4.2 评估方法

所有组合使用 2023 年 OOS 评估，与 LGB 预测期对齐。输入因子按样本内 Sharpe（2020–2022 年）排序后选择，避免因子排名中的前视偏差。通过日超额收益的成对 Spearman 相关系数监控输入因子相关性。

5 实验结果




图 1: (左) 因子池表现: 最佳和平均 Sharpe。(中) 方法对比。(右) 混合因子规模与 Sharpe 关系。

5.1 因子池对比

我们评估了 55 个不同组合，结果汇总于表2。

表 2: 因子池表现汇总

因子池	最佳 Sharpe	平均 Sharpe	最佳 IC	组合数
仅混合	10.41	9.11	0.0266	12
全部组合	9.94	9.03	0.0420	9
明确风格	7.96	7.43	0.0356	16
风格均衡	6.92	6.68	0.0358	3

最显著的结果：混合因子平均 Sharpe 比明确风格最佳组高 22.6%。这证实了我们的假设——被标注为”混合”的因子远非”不可分类的噪音”，而是蕴含多维度信号的天然分散化优质输入。

5.2 方法对比

表 3: 各方法在不同因子池下的表现

方法	全场最佳	最佳因子池	平均 S(混合)	平均 S(明确)
LGB	12.51	混合 + 明确	10.55	—
ICIR	10.41	混合	9.38	7.44
Ridge	9.24	混合	8.82	7.31
等权	9.94	全部	9.12	7.61

5.3 Top 10 组合




图 2: Sharpe 排名前 10 组合。紫色 =LGB, 红色 =ICIR, 绿色 =Ridge, 蓝色 = 等权。

表 4: Top 10 表现最佳组合

排名	策略	方法	N	Sharpe IC
1	混合 + 明确混合	LGB	10	12.51 0.0510
2	混合 Top-5	LGB	5	10.55 0.0336
3	混合 Top-5	ICIR	5	10.41 0.0266
4	混合 + 明确混合	LGB	14	9.95 0.0522
5	全部 Top-15	EW	15	9.94 0.0394
6	混合 Top-8	ICIR	8	9.71 0.0236
7	混合 Top-10	LGB	10	9.62 0.0491
8	混合 Top-10	EW	10	9.61 0.0299
9	全部 Top-15	ICIR	15	9.28 0.0402
10	混合 Top-7	EW	7	9.27 0.0246

5.4 组内 vs 组间相关性




图 3: 各风格组内因子成对平均相关性。越高代表冗余度越大。

各明确风格组内日收益的成对绝对相关系数:

分组	平均 Corr
流动性	0.367
反转	0.212
动量	0.165
微观结构	0.125

流动性因子组内冗余度最高 (0.367)，而微观结构因子最为多样 (0.125)。这解释了为什么流动性组合从 ICIR 加权中获益最大——稳定但中度冗余的因子通过差异化权重降低了集中风险。

5.5 核心发现总结

1. **混合因子是被忽视的王者。**此前作为”不可分类”被排除，组合中平均 Sharpe 达 9.11，高出明确风格 22.6%。其多维度特性提供了内置分散化。
2. **ICIR 加权在小规模组合中优势显著。** $N \leq 5$ 时，ICIR 加权持续优于等权和 Ridge。随 N 增大，等权逐渐追平。
3. **LGB 挖掘跨风格协同效应。**最佳结果 ($S=12.51$) 来自 LGB 结合混合与明确因子。非线性模型捕捉了线性加权无法获取的因子交互。
4. **风格分散化至关重要。**跨组组合 (平均 $S=7.47$) 显著优于组内 (平均 $S=4.66$)。从不同经济组选择因子比从单一组内选择最优因子更重要。
5. **$N=8-10$ 为最优区间。**过少缺乏分散，过多引入噪音。最佳组合集中在 $N=8-10$ 。

6 提交的最终因子

我们从相关性贪心筛选中得到以下 10 个两两相关性 < 0.5 的因子，提交竞赛评估：

表 5: 提交因子清单 (两两相关性 < 0.5)

#	表达式	IC	Sharpe	分组
1	<code>-rank(abs(zscore(turnover_rate)))</code>	0.0280	7.61	流动性
2	<code>-zscore(mom_vol_conf) * zscore(rev_vol_conf)</code>	0.0257	4.18	动量
3	<code>zscore(vol_60d) - zscore(turnover_rate)</code>	0.0183	3.52	波动率
4	<code>-zscore(turnover_rate) * zscore(volume_breakout)</code>	0.0249	5.32	微观结构
5	<code>zscore(ret_20d) - zscore(turnover_rate)</code>	0.0155	3.92	混合
6	<code>-rank(volume_breakout) - rank(ret_20d)</code>	0.0172	3.91	混合
7	<code>zscore(rsi_14) - zscore(mom_vol_conf)</code>	0.0213	5.23	混合
8	<code>-zscore(bollinger_pos) * zscore(vol_ratio)</code>	0.0228	4.78	混合
9	<code>-rank(log_dollar_vol) - rank(ret_120d_skip5)</code>	0.0256	5.03	混合
10	<code>zscore(ret_120d_skip5) - zscore(turnover_rate)</code>	0.0187	4.62	混合

这 10 个因子覆盖 5 个经济分组，混合/明确比例为 6:4，体现了混合因子在组合中不成比例的贡献。

7 发现的创新模式

7.1 混合因子悖论

最重要的发现是混合标注因子的超常表现。传统因子研究强调纯净的经济叙事；我们的结果表明，同时捕捉多个经济维度的因子——虽更难解释——对组合构建更有价值。我们推测这与 A 股市场的独特特征有关：高散户参与度、板块轮动和政策驱动行情使多维度信号更具优势。

7.2 ICIR 作为通用加权指标

在所有因子池中，ICIR 加权在 $N \leq 5$ 时匹配或超过等权，在更大 N 时仍保持竞争力。这表明 ICIR 应作为 Alpha 组合的默认加权方案，等权作为稳健性检验。

7.3 子进程计算的内存安全保障

平台将所有重计算（LGB 训练、大型 EW 组合）运行在独立子进程中，通过结果文件通信，确保内存使用可预测。这一架构决策——由 Python 的 GIL 和内存碎片问题驱动——使得在普通硬件（16 GB RAM）上也能可靠运行。

7.4 基于表达式的因子复用

通过将组合方法和权重编码进表达式字符串（如 `superalpha[icir](0.35*A + 0.65*B)`），平台实现了组合结果作为高层组合输入的零成本复用。这种符号化方法避免了缓存原始因子矩阵所需的每个 80 MB 的存储成本。

8 未来工作方向

1. **混合因子深度分析：**鉴于混合因子的意外强度，通过表达式结构相似性聚类 512 个混合因子，发现新的 Alpha 来源。
2. **自适应加权：**当前 ICIR 和 Ridge 权重为静态。基于近期 IC 稳定性的动态权重调整可在市场制度变化时提升 OOS 表现。
3. **多层 LGB 堆叠：**借助 LGB 缓存机制（每个训练模型约 5 MB），两层或三层 LGB 堆叠变得可行。初步测试单层 LGB 达到 $S=12.51$ ，双层架构可能突破 15。
4. **分钟数据整合：**平台当前支持 970 天分钟级数据的 14 个衍生字段。将组合框架扩展至日内信号可捕捉日频数据遗漏的微观结构效应。
5. **因子衰减建模：**当前所有回测使用等权历史窗口。建模因子表现衰减（如近期 IC 的指数加权）可提升 OOS 稳健性。
6. **跨市场验证：**组合方法论是市场无关的。在美股、港股等市场验证可测试混合因子发现的普适性。

9 结论

YYB 量化研究平台证明了系统化因子分类与多策略组合可产生 Sharpe 超过 12 的 Alpha 组合。核心洞察——”混合”因子，传统上被当作不可分类噪音丢弃，实际上是组合构建中最有价值的输入——挑战了传统因子研究方法论，引发对”因子纯净度”作为优良属性的重新评估。平台的架构创新（子进程计算的内存安全、基于表达式的因子复用、ICIR/Ridge 加权方法）为持续的 Alpha 研究提供了可投产的基础。通过实验验证方法论后筛选的 10 个提交因子，代表了平台当前的最先进产出。